

Evaluated Model

DeepSeek-V3	0.18	0.32	0.25	0.29	0.28
o1-mini	0.29	0.29	0.30	0.34	0.29
GPT-4o	0.20	0.31	0.33	0.23	0.24
GPT-4o-mini	0.35	0.45	0.36	0.42	0.32
Llama-3.1-70B	0.37	0.31	0.24	0.21	0.20

Llama-3.1-70B

GPT-4o-mini

GPT-4o

o1-mini

DeepSeek-V3

Target Model